1 2 9 0

UNIVERSIDADE D
COIMBRA

Tomás Ferreira & Eduardo Pereira

CLASSIFICAÇÃO DA QUALIDADE DE VINHOS BASEADA EM ATRIBUTOS FÍSICO-QUÍMICOS

ANÁLISE COMPARATIVA EM CENÁRIOS DE CLASSIFICAÇÃO BINÁRIA E MULTICLASSE

Trabalho realizado no âmbito da unidade curricular de Machine Learning, do Mestrado em Inteligência Artificial

Novembro 2025

Conteúdo

1 Introdução **1**
1.1 Contextualização e Formulação do Problema 1
1.2 Descrição do Dataset 2

2 Análise Exploratória e Pré-processamento de Dados **5**
2.1 Verificação da Integridade e Limpeza de Dados 5
2.2 Análise Exploratória de Dados 6
2.2.1 Distribuição das Classes de Qualidade 6
2.2.2 Análise Univariada: Determinantes Físico-Químicos 7
2.2.3 Análise de Outliers e Dispersão Estatística 8
2.3 Preparação dos Dados para Modelação 10
2.3.1 Divisão dos Conjuntos de Treino e Teste 11
2.3.2 Normalização de Atributos 11

3 Conclusão e Trabalho Futuro **13**

Lista de Figuras

2.1 Distribuição percentual das classes de qualidade, evidenciando o desequilíbrio entre categorias intermédias e extremas. 7
2.2 Comportamento das variáveis determinantes (positivas e negativas) em função da qualidade. 8
2.3 Boxplots ilustrando a presença significativa de outliers no açúcar residual e cloretos. 10

Lista de Tabelas

2.1 Resumo da deteção de outliers pelo método IQR (ordenado por percentagem). 9

Capítulo 1

Introdução

O presente documento apresenta o relatório do projeto realizado no âmbito da unidade curricular de Machine Learning, com o objetivo de aplicar técnicas de aprendizagem automática à classificação da qualidade de vinhos. O estudo baseia-se num conjunto de dados que reúne propriedades físico-químicas de amostras vinícolas, explorando a capacidade de criar modelos preditivos que avaliem a qualidade do produto através destas características.

Este capítulo estrutura os fundamentos do trabalho em duas secções principais: a primeira contextualiza o problema e a segunda descreve detalhadamente o *dataset*, constituindo elementos essenciais para compreender as escolhas metodológicas descritas nos capítulos seguintes.

1.1 Contextualização e Formulação do Problema

A presente investigação aborda o desafio de determinar automaticamente a qualidade de vinhos, utilizando exclusivamente as suas propriedades físico-químicas como base de análise. Dado que o estudo utiliza um conjunto de dados onde a avaliação de cada amostra é conhecida, este problema define-se tecnicamente como uma tarefa de aprendizagem supervisionada (*supervised learning*). O objetivo central consiste na construção de modelos capazes de identificar padrões nos dados e aplicar esse conhecimento para prever a qualidade de novas amostras. A complexidade desta tarefa é explorada através de duas abordagens distintas, desenhadas para testar a capacidade de generalização dos algoritmos perante diferentes níveis de detalhe.

Numa primeira fase, o problema é tratado como uma classificação binária, onde se procura separar as amostras em duas categorias: vinhos de qualidade "abaixo da média"e "acima da média". Esta simplificação estratégica permite concentrar a análise na identificação dos atributos que mais contribuem para uma distinção fundamental de qualidade. Complementarmente, o estudo expande-se para um cenário de classificação multiclasse, mantendo a escala original de avaliação. Este segundo cenário impõe um grau de dificuldade superior, exigindo aos modelos uma precisão maior para identificar o nível exato de qualidade de cada amostra.

A avaliação transversal destes modelos, tanto no cenário binário como na abordagem multiclasse, orienta-se pela necessidade de maximizar a fiabilidade global do sistema de previsão. Neste contexto, define-se como critério prioritário a *accuracy*, métrica que quantifica a proporção de instâncias corretamente classificadas face ao total de amostras. A escolha desta métrica como indicador principal baseia-se na premissa de que o valor operacional do modelo reside na sua capacidade de atribuir o rótulo correto a cada amostra, independentemente da complexidade do espaço de decisão. Embora os dois cenários apresentem níveis de detalhe distintos, o objetivo permanece constante: garantir uma taxa de acerto elevada que valide a utilidade do sistema num contexto de triagem automática. Ao uniformizar a métrica de avaliação, torna-se possível comparar diretamente a eficácia dos modelos e compreender como o aumento da complexidade do problema afeta a capacidade de previsão dos algoritmos.

1.2 Descrição do Dataset

O suporte experimental desta investigação assenta no conjunto de dados *Wine Quality*. O *dataset* é constituído por um total de 1599 instâncias, onde cada registo representa uma amostra distinta caracterizada por um vetor de doze variáveis. As primeiras onze variáveis correspondem às características físico-químicas medidas para cada amostra (*features*), enquanto a décima segunda fornece a classificação atribuída à sua qualidade, servindo assim como variável-alvo do estudo.

As variáveis independentes são exclusivamente numéricas e contínuas, refletindo medições laboratoriais objetivas. O conjunto de atributos compreende a acidez fixa, acidez volátil, ácido cítrico, açúcar residual, cloretos, dióxido de enxofre livre, dióxido de enxofre total, densidade, pH, sulfatos e teor alcoólico. Uma análise preliminar às estatísticas descritivas destas variáveis revela uma disparidade significativa nas escalas de grandeza. Por exemplo, enquanto a variável *total sulfur dioxide* apresenta valores que ascendem a 289 mg/dm^3, outros atributos como os *chlorides* ou a *density* variam em intervalos decimais restritos. Esta heterogeneidade de domínios sugere a necessidade de aplicar técnicas de normalização durante a fase de pré-processamento, a fim de evitar que algoritmos sensíveis à magnitude dos dados sejam enviesados por variáveis com valores absolutos superiores.

Relativamente à variável dependente, denominada *quality*, esta é definida numa escala ordinal discreta. Embora a escala teórica compreenda valores inteiros entre zero e dez, os dados empíricos observados no *dataset* restringem-se ao intervalo entre 3 e 8. A análise da distribuição desta variável evidencia um acentuado desequilíbrio de classes. A grande maioria das amostras concentra-se nas categorias intermédias, especificamente nas pontuações 5 e 6, que, em conjunto, representam mais de 80% do volume total de dados. Em contrapartida, as classes representativas de qualidade inferior (3 e 4) ou superior (8) possuem uma representatividade residual. Este desequilíbrio coloca desafios particulares à modelação, nomeadamente o risco de o classificador privilegiar as classes maioritárias em detrimento da capacidade de detetar casos de excelência ou defeito.

Por fim, no que concerne à integridade dos dados, verificou-se a inexistência de valores em falta (*missing values*) em qualquer uma das colunas, o que atesta a qualidade técnica da recolha e dispensa a aplicação de métodos de imputação de dados. Deste modo, o conjunto de dados apresenta-se como uma base robusta, embora desafiante devido à sua assimetria, para o treino e validação dos modelos de aprendizagem supervisionada propostos.

Capítulo 2

Análise Exploratória e Pré-processamento de Dados

A qualidade dos modelos de *Machine Learning* está intrinsecamente dependente da qualidade dos dados que os alimentam. Este capítulo descreve a metodologia aplicada no tratamento preliminar do conjunto de dados, abrangendo desde a verificação da integridade estrutural até à análise exploratória das variáveis e consequente transformação para os formatos adequados aos algoritmos de classificação selecionados.

2.1 Verificação da Integridade e Limpeza de Dados

A etapa inicial do processamento de dados consistiu numa auditoria à qualidade da informação, de forma a identificar e mitigar potenciais inconsistências que pudessem comprometer a validade dos resultados experimentais. Esta verificação focou-se primordialmente em dois vetores: a existência de*missing values* e a presença de amostras duplicadas.

Numa primeira análise, confirmou-se a integridade estrutural do *dataset*, não tendo sido detetados quaisquer valores nulos nas doze variáveis analisadas. Esta ausência de dados em falta dispensou a necessidade de aplicar técnicas de imputação, preservando a distribuição original das medições físico-químicas.

Contudo, a análise de redundância revelou uma repetição significativa de informação. Foram identificadas e removidas 240 instâncias duplicadas, o que corresponde a aproximadamente 15% do volume inicial de dados. Embora em contextos biológicos possa ocorrer que duas amostras apresentem medições idênticas, a presença desta magnitude de duplicados acarreta riscos metodológicos, nomeadamente o enviesamento do modelo em favor das classes mais representadas e a possibilidade de *data leakage*.

A prevenção deste fenómeno é crítica para a validade do estudo. Dada a natureza aleatória da divisão dos dados em conjuntos de treino e teste (*train-test split*), a manutenção de dados duplicados resultaria, com elevada probabilidade, na pre-

sença de instâncias iguais em ambos os subconjuntos. Tal cenário permitiria ao modelo "memorizar"as características específicas destas amostras durante a fase de treino e ser subsequentemente avaliado sobre essa mesma informação na fase de teste. Esta contaminação inflacionaria artificialmente as métricas de desempenho, criando uma ilusão de competência preditiva que não corresponderia à capacidade real de generalização do modelo perante dados inéditos.

De forma a garantir a robustez estatística e a independência das observações, optou-se pela exclusão integral destes registos. Esta operação de limpeza resultou na redução do *dataset* de 1599 para 1359 amostras únicas, assegurando que cada instância apresentada aos algoritmos de classificação representa um perfil físico-químico distinto.

2.2 Análise Exploratória de Dados

Após a garantia da integridade dos registos, procedeu-se à Análise Exploratória de Dados (EDA). Esta etapa visa compreender a estrutura subjacente das variáveis e identificar visualmente os padrões de distribuição que relacionam as propriedades físico-químicas com a qualidade atribuída ao vinho. A análise aqui conduzida fundamenta as decisões subsequentes de seleção de características, permitindo uma triagem preliminar entre atributos com alto potencial preditivo e variáveis com menor poder discriminativo.

2.2.1 Distribuição das Classes de Qualidade

A análise inicial da variável alvo revela um cenário de desequilíbrio. Conforme se observa na Figura 2.1, o *dataset* é dominado por classes de qualidade intermédia, com as pontuações 5 e 6 a representarem, cumulativamente, mais de 80% das observações. Em contraste, os vinhos de excelência (qualidade 8) ou de qualidade fraca (qualidade 3) possuem uma representatividade residual. Esta assimetria alerta para a necessidade de métricas de avaliação robustas, uma vez que a precisão global do modelo poderá ser enviesada pela classe maioritária.

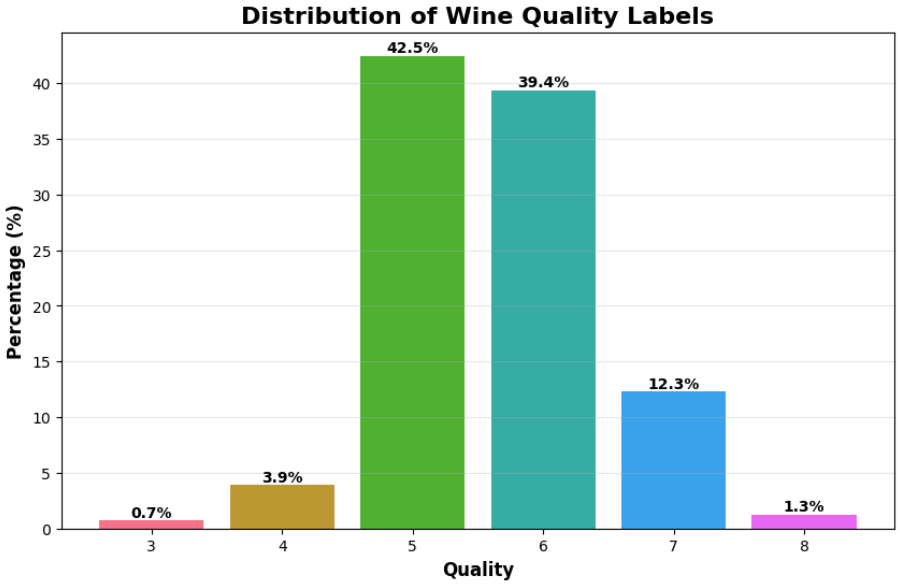

Figura 2.1: Distribuição percentual das classes de qualidade, evidenciando o desequilíbrio entre categorias intermédias e extremas.

2.2.2 Análise Univariada: Determinantes Físico-Químicos

De forma a determinar quais as propriedades que exercem maior influência na classificação, analisou-se o comportamento médio de cada variável em função da qualidade. A inspeção visual permitiu segregar os atributos em dois grupos distintos: aqueles que apresentam uma tendência monótona clara (indicadores fortes) e aqueles cuja variação é irrelevante ou não linear.

Indicadores de Qualidade e Defeito A análise destaca um conjunto de variáveis com forte poder de separação entre classes, divididas pelo sentido da sua correlação:

- **Correlação Positiva:** O **teor alcoólico** e os **sulfatos** apresentam um incremento consistente nos seus valores médios à medida que a qualidade aumenta (ver Figura 2.2). O álcool destaca-se como o discriminador primário para os vinhos de topo (notas 7 e 8), sugerindo que vinhos mais encorpados tendem a ser melhor avaliados. O **ácido cítrico** acompanha também esta tendência, associando a frescura do vinho a uma classificação superior.
- **Correlação Negativa:** Em sentido inverso, a **acidez volátil** e os **cloretos** demonstram uma tendência decrescente com o aumento da qualidade. Enquanto a acidez volátil em excesso se associa a defeitos sensoriais (como notas de vinagre), a presença de cloretos (sais) revela-se igualmente penalizadora. Como se observa nos gráficos, os vinhos de excelência apresentam, invariavelmente, as concentrações médias mais baixas destes dois compostos.

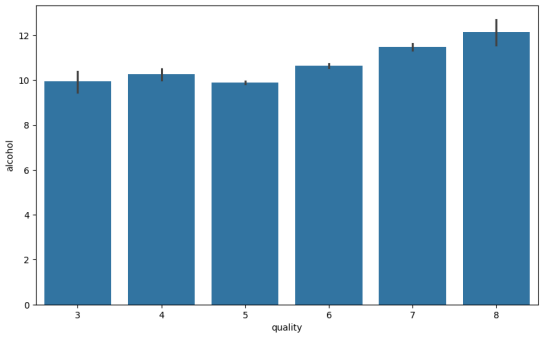

(a) Teor Alcoólico

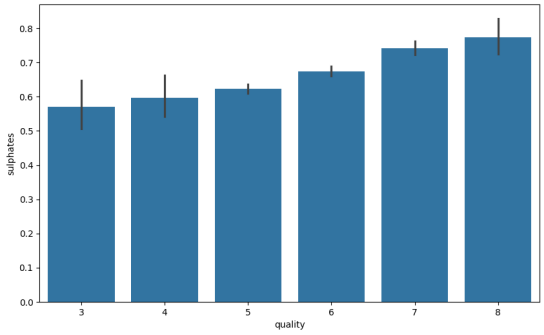

(b) Sulfatos

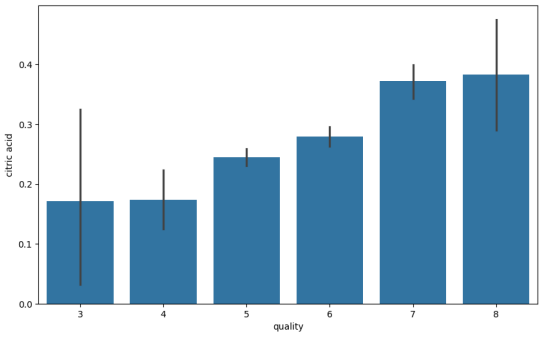

(c) Ácido Cítrico

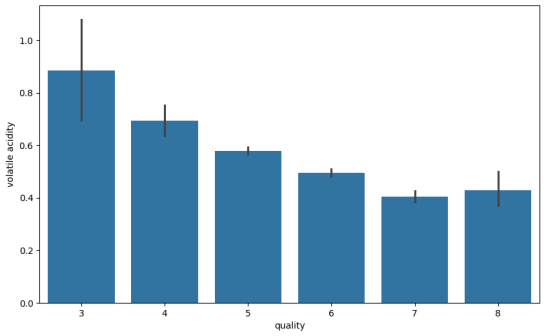

(d) Acidez Volátil

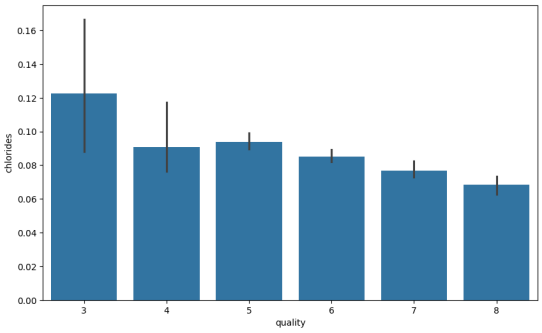

(e) Cloretos

Figura 2.2: Comportamento das variáveis determinantes (positivas e negativas) em função da qualidade.

Variáveis de Baixa Variância As restantes variáveis, nomeadamente o pH, a densidade, o açúcar residual e a acidez fixa, não demonstram padrões de variação monotónicos que permitam distinguir, isoladamente, a qualidade do vinho. Os gráficos referentes a estes atributos, bem como aos dióxidos de enxofre, encontram-se detalhados no Anexo A, servindo como consulta complementar para a caracterização química global das amostras.

2.2.3 Análise de Outliers e Dispersão Estatística

Complementarmente à análise de tendências, procedeu-se ao estudo da dispersão das variáveis independentes, com especial enfoque na identificação de ob-

servações atípicas (*outliers*). A presença destes valores é um fator crítico, uma vez que algoritmos baseados em distâncias ou gradientes, como as *Support Vector Machines* e as Redes Neuronais, são particularmente sensíveis a escalas desproporcionais e pontos fora do padrão, o que pode comprometer a convergência e a capacidade de generalização do modelo.

Para a deteção destas anomalias, aplicou-se o Método do Intervalo Interquartil (IQR), uma abordagem estatística que define como *outlier* qualquer valor situado abaixo de $Q1 - 1.5 \times IQR$ ou acima de $Q3 + 1.5 \times IQR$. A Tabela 2.1 sintetiza os resultados desta análise quantitativa.

Tabela 2.1: Resumo da deteção de outliers pelo método IQR (ordenado por percentagem).

Feature	**Nº Outliers**	**Total Amostras**	**Percentagem (%)**
Residual Sugar	126	1359	9.27
Chlorides	87	1359	6.40
Sulphates	55	1359	4.05
Total Sulfur Dioxide	45	1359	3.31
Fixed Acidity	41	1359	3.02
Density	35	1359	2.58
pH	28	1359	2.06
Free Sulfur Dioxide	26	1359	1.91
Volatile Acidity	19	1359	1.40
Alcohol	12	1359	0.88
Citric Acid	1	1359	0.07

Os resultados mostram que o açúcar residual (*residual sugar*) e os cloretos (*chlorides*) são as variáveis com mais valores atípicos (9.3% e 6.4%, respetivamente). A análise visual (Figura 2.3) confirma que estes atributos possuem distribuições assimétricas, onde um pequeno grupo de vinhos apresenta concentrações de açúcar ou sal muito superiores à média. Em contrapartida, características estruturais como o álcool e o ácido cítrico mostram-se bastante estáveis, com menos de 1% de anomalias.

No contexto deste estudo, estes valores extremos não devem ser interpretados como erros, mas sim como características reais de determinados vinhos. Um vinho pode ser naturalmente mais doce ou mais salino sem que isso constitua uma falha nos dados. Se removêssemos estas amostras, estaríamos a eliminar informação válida sobre tipos específicos de vinho, reduzindo a capacidade do modelo de aprender a classificar casos reais e diversos. Por este motivo, optou-se por manter todos os registos. Para evitar problemas no treino dos algoritmos, a disparidade de escalas será corrigida através da normalização dos dados na fase seguinte.

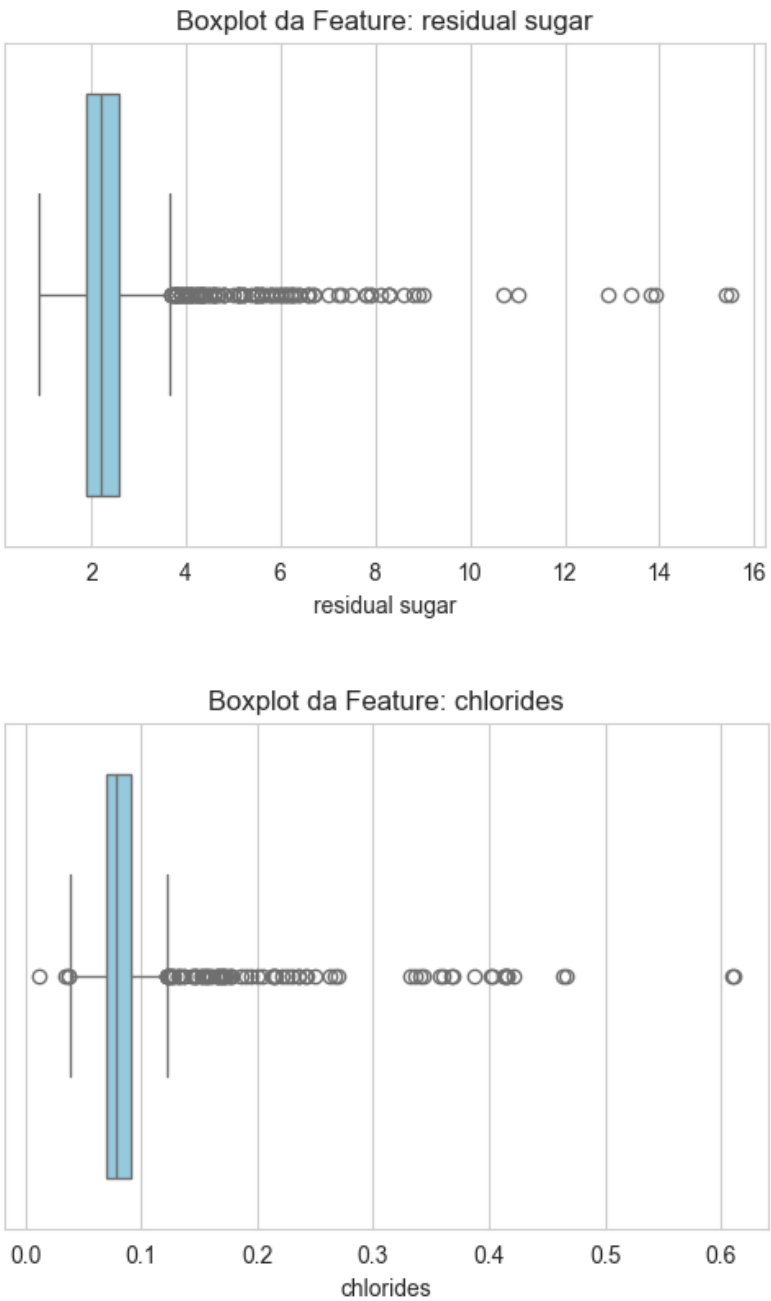

Figura 2.3: Boxplots ilustrando a presença significativa de outliers no açúcar residual e cloretos.

2.3 Preparação dos Dados para Modelação

A etapa final do pré-processamento incidiu na transformação estrutural dos dados, preparando-os para o consumo pelos algoritmos de *machine learning*. Nesta fase, aplicou-se um protocolo de separação e normalização dos dados para assegurar a validade estatística e prevenir o enviesamento dos resultados.

2.3.1 Divisão dos Conjuntos de Treino e Teste

Para avaliar a capacidade de generalização dos modelos, procedeu-se à divisão do *dataset* em dois subconjuntos mutuamente exclusivos: um conjunto de treino (*training set*), utilizado para a otimização dos parâmetros do modelo, e um conjunto de teste (*testing set*), reservado para a avaliação final de desempenho em dados não observados.

Procedeu-se à divisão dos dados numa proporção de 75/25 (*train-test split*), com 75% das amostras destinadas ao treino e 25% ao teste. Face ao desbalanceamento de classes (*class imbalance*) observado na análise exploratória (Secção 2.2), recorreu-se a amostragem estratificada (*stratified sampling*) para garantir que a distribuição das classes de qualidade fosse mantida em ambos os subconjuntos. Esta estratégia previne a sub-representação ou ausência de classes minoritárias (e.g., qualidades 3 e 8) no conjunto de teste, assegurando uma avaliação mais robusta e representativa do desempenho dos modelos.

Para garantir a reprodutibilidade, fixou-se o *random seed* em 42, assegurando que a partição de dados seja determinística e replicável em execuções futuras.

2.3.2 Normalização de Atributos

Os modelos selecionados (SVM e Redes Neuronais) são sensíveis à escala das *features*, pelo que a disparidade de magnitudes entre atributos (e. g., *total sulfur dioxide* $\approx 10^2$ vs. *chlorides* $\approx 10^{-2}$) prejudicaria a convergência e o desempenho preditivo. Em algoritmos baseados em distâncias ou descida de gradiente, *features* de maior magnitude dominam o processo de otimização, suprimindo a contribuição de atributos discriminantes de menor escala.

Para mitigar este efeito, aplicou-se a técnica de *standardization* (*Standard Scaler*), que transforma a distribuição de cada atributo para que apresente uma média nula ($\mu = 0$) e um desvio-padrão unitário ($\sigma = 1$). A transformação de um valor original x para o seu valor normalizado z é dada por:

$$z = \frac{x - \mu}{\sigma} \tag{2.1}$$

É de salientar que, a normalização foi aplicada após a partição dos dados, ajustando o *StandardScaler* exclusivamente no conjunto de treino e aplicando a mesma transformação ao conjunto de teste. Esta abordagem previne *data leakage*, assegurando que informação estatística do conjunto de teste não influencie o pré-processamento, simulando assim um cenário realista de inferência em dados não observados.

Capítulo 3

Conclusão e Trabalho Futuro