1 2 9 0

UNIVERSIDADE D
COIMBRA

Tomás Ferreira & Eduardo Pereira

CLASSIFICAÇÃO DA QUALIDADE DE VINHOS BASEADA EM ATRIBUTOS FÍSICO-QUÍMICOS

ANÁLISE COMPARATIVA EM CENÁRIOS DE CLASSIFICAÇÃO BINÁRIA E MULTICLASSE

Trabalho realizado no âmbito da unidade curricular de Machine Learning, do Mestrado em Inteligência Artificial

Novembro 2025

Conteúdo

1 Introdução **1**
1.1 Contextualização e Formulação do Problema 1
1.2 Descrição do Dataset 2

2 Análise Exploratória e Pré-processamento de Dados **5**
2.1 Verificação da Integridade e Limpeza de Dados 5
2.2 Análise Exploratória de Dados 6
2.2.1 Distribuição das Classes de Qualidade 6
2.2.2 Análise Univariada: Determinantes Físico-Químicos 7
2.2.3 Análise de Outliers e Dispersão Estatística 8
2.3 Preparação dos Dados para Modelação 10
2.3.1 Divisão dos Conjuntos de Treino e Teste 11
2.3.2 Normalização de Atributos 11

3 Metodologia Experimental e Análise de Resultados **13**
3.1 Classificação Binária 13
3.1.1 Definição da Variável Alvo e Balanceamento de Classes . . . 13
3.1.2 Otimização de Hiperparâmetros em Redes Neuronais 14
3.1.3 Análise de Robustez e Estabilidade 16
3.1.4 Ensemble Learning: Random Forest 18
3.1.5 Otimização de Hiperparâmetros em Random Forest 18
3.1.6 Análise de Robustez e Estabilidade 20

4 Conclusão e Trabalho Futuro **23**

Lista de Figuras

2.1 Distribuição percentual das classes de qualidade, evidenciando o desequilíbrio entre categorias intermédias e extremas. 7
2.2 Comportamento das variáveis determinantes (positivas e negativas) em função da qualidade. 8
2.3 Boxplots ilustrando a presença significativa de outliers no açúcar residual e cloretos. 10

Lista de Tabelas

2.1 Resumo da deteção de outliers pelo método IQR (ordenado por percentagem). 9

3.1 Top 5 Configurações de Redes Neuronais (Média $\pm$ Desvio Padrão de 3 execuções). 15
3.2 Estatísticas descritivas de desempenho após 30 execuções independentes do modelo final 16
3.3 Métricas de desempenho por classe em 30 execuções independentes ($\mu \pm \sigma$). 17
3.4 Top 5 Configurações de Random Forest (Ordenadas por Test Accuracy). 19
3.5 Estatísticas descritivas do Random Forest após 30 execuções independentes. 20
3.6 Métricas médias e desvio padrão por classe no Random Forest ($\mu \pm \sigma$). 21

Capítulo 1

Introdução

O presente documento apresenta o relatório do projeto realizado no âmbito da unidade curricular de Machine Learning, com o objetivo de aplicar técnicas de aprendizagem automática à classificação da qualidade de vinhos. O estudo baseia-se num conjunto de dados que reúne propriedades físico-químicas de amostras vinícolas, explorando a capacidade de criar modelos preditivos que avaliem a qualidade do produto através destas características.

Este capítulo estrutura os fundamentos do trabalho em duas secções principais: a primeira contextualiza o problema e a segunda descreve detalhadamente o *dataset*, constituindo elementos essenciais para compreender as escolhas metodológicas descritas nos capítulos seguintes.

1.1 Contextualização e Formulação do Problema

A presente investigação aborda o desafio de determinar automaticamente a qualidade de vinhos, utilizando exclusivamente as suas propriedades físico-químicas como base de análise. Dado que o estudo utiliza um conjunto de dados onde a avaliação de cada amostra é conhecida, este problema define-se tecnicamente como uma tarefa de aprendizagem supervisionada (*supervised learning*). O objetivo central consiste na construção de modelos capazes de identificar padrões nos dados e aplicar esse conhecimento para prever a qualidade de novas amostras. A complexidade desta tarefa é explorada através de duas abordagens distintas, desenhadas para testar a capacidade de generalização dos algoritmos perante diferentes níveis de detalhe.

Numa primeira fase, o problema é tratado como uma classificação binária, onde se procura separar as amostras em duas categorias: vinhos de qualidade "abaixo da média"e "acima da média". Esta simplificação estratégica permite concentrar a análise na identificação dos atributos que mais contribuem para uma distinção fundamental de qualidade. Complementarmente, o estudo expande-se para um cenário de classificação multiclasse, mantendo a escala original de avaliação. Este segundo cenário impõe um grau de dificuldade superior, exigindo aos modelos uma precisão maior para identificar o nível exato de qualidade de cada amostra.

A avaliação transversal destes modelos, tanto no cenário binário como na abordagem multiclasse, orienta-se pela necessidade de maximizar a fiabilidade global do sistema de previsão. Neste contexto, define-se como critério prioritário a *accuracy*, métrica que quantifica a proporção de instâncias corretamente classificadas face ao total de amostras. A escolha desta métrica como indicador principal baseia-se na premissa de que o valor operacional do modelo reside na sua capacidade de atribuir o rótulo correto a cada amostra, independentemente da complexidade do espaço de decisão. Embora os dois cenários apresentem níveis de detalhe distintos, o objetivo permanece constante: garantir uma taxa de acerto elevada que valide a utilidade do sistema num contexto de triagem automática. Ao uniformizar a métrica de avaliação, torna-se possível comparar diretamente a eficácia dos modelos e compreender como o aumento da complexidade do problema afeta a capacidade de previsão dos algoritmos.

1.2 Descrição do Dataset

O suporte experimental desta investigação assenta no conjunto de dados *Wine Quality*. O *dataset* é constituído por um total de 1599 instâncias, onde cada registo representa uma amostra distinta caracterizada por um vetor de doze variáveis. As primeiras onze variáveis correspondem às características físico-químicas medidas para cada amostra (*features*), enquanto a décima segunda fornece a classificação atribuída à sua qualidade, servindo assim como variável-alvo do estudo.

As variáveis independentes são exclusivamente numéricas e contínuas, refletindo medições laboratoriais objetivas. O conjunto de atributos compreende a acidez fixa, acidez volátil, ácido cítrico, açúcar residual, cloretos, dióxido de enxofre livre, dióxido de enxofre total, densidade, pH, sulfatos e teor alcoólico. Uma análise preliminar às estatísticas descritivas destas variáveis revela uma disparidade significativa nas escalas de grandeza. Por exemplo, enquanto a variável *total sulfur dioxide* apresenta valores que ascendem a 289 mg/dm^3, outros atributos como os *chlorides* ou a *density* variam em intervalos decimais restritos. Esta heterogeneidade de domínios sugere a necessidade de aplicar técnicas de normalização durante a fase de pré-processamento, a fim de evitar que algoritmos sensíveis à magnitude dos dados sejam enviesados por variáveis com valores absolutos superiores.

Relativamente à variável dependente, denominada *quality*, esta é definida numa escala ordinal discreta. Embora a escala teórica compreenda valores inteiros entre zero e dez, os dados empíricos observados no *dataset* restringem-se ao intervalo entre 3 e 8. A análise da distribuição desta variável evidencia um acentuado desequilíbrio de classes. A grande maioria das amostras concentra-se nas categorias intermédias, especificamente nas pontuações 5 e 6, que, em conjunto, representam mais de 80% do volume total de dados. Em contrapartida, as classes representativas de qualidade inferior (3 e 4) ou superior (8) possuem uma representatividade residual. Este desequilíbrio coloca desafios particulares à modelação, nomeadamente o risco de o classificador privilegiar as classes maioritárias em detrimento da capacidade de detetar casos de excelência ou defeito.

Por fim, no que concerne à integridade dos dados, verificou-se a inexistência de valores em falta (*missing values*) em qualquer uma das colunas, o que atesta a qualidade técnica da recolha e dispensa a aplicação de métodos de imputação de dados. Deste modo, o conjunto de dados apresenta-se como uma base robusta, embora desafiante devido à sua assimetria, para o treino e validação dos modelos de aprendizagem supervisionada propostos.

Capítulo 2

Análise Exploratória e Pré-processamento de Dados

A qualidade dos modelos de *Machine Learning* está intrinsecamente dependente da qualidade dos dados que os alimentam. Este capítulo descreve a metodologia aplicada no tratamento preliminar do conjunto de dados, abrangendo desde a verificação da integridade estrutural até à análise exploratória das variáveis e consequente transformação para os formatos adequados aos algoritmos de classificação selecionados.

2.1 Verificação da Integridade e Limpeza de Dados

A etapa inicial do processamento de dados consistiu numa auditoria à qualidade da informação, de forma a identificar e mitigar potenciais inconsistências que pudessem comprometer a validade dos resultados experimentais. Esta verificação focou-se primordialmente em dois vetores: a existência de *missing values* e a presença de amostras duplicadas.

Numa primeira análise, confirmou-se a integridade estrutural do *dataset*, não tendo sido detetados quaisquer valores nulos nas doze variáveis analisadas. Esta ausência de dados em falta dispensou a necessidade de aplicar técnicas de imputação, preservando a distribuição original das medições físico-químicas.

Contudo, a análise de redundância revelou uma repetição significativa de informação. Foram identificadas e removidas 240 instâncias duplicadas, o que corresponde a aproximadamente 15% do volume inicial de dados. Embora em contextos biológicos possa ocorrer que duas amostras apresentem medições idênticas, a presença desta magnitude de duplicados acarreta riscos metodológicos, nomeadamente o enviesamento do modelo em favor das classes mais representadas e a possibilidade de *data leakage*.

A prevenção deste fenómeno é crítica para a validade do estudo. Dada a natureza aleatória da divisão dos dados em conjuntos de treino e teste (*train-test split*), a manutenção de dados duplicados resultaria, com elevada probabilidade, na pre-

sença de instâncias iguais em ambos os subconjuntos. Tal cenário permitiria ao modelo "memorizar"as características específicas destas amostras durante a fase de treino e ser subsequentemente avaliado sobre essa mesma informação na fase de teste. Esta contaminação inflacionaria artificialmente as métricas de desempenho, criando uma ilusão de competência preditiva que não corresponderia à capacidade real de generalização do modelo perante dados inéditos.

De forma a garantir a robustez estatística e a independência das observações, optou-se pela exclusão integral destes registos. Esta operação de limpeza resultou na redução do *dataset* de 1599 para 1359 amostras únicas, assegurando que cada instância apresentada aos algoritmos de classificação representa um perfil físico-químico distinto.

2.2 Análise Exploratória de Dados

Após a garantia da integridade dos registos, procedeu-se à Análise Exploratória de Dados (EDA). Esta etapa visa compreender a estrutura subjacente das variáveis e identificar visualmente os padrões de distribuição que relacionam as propriedades físico-químicas com a qualidade atribuída ao vinho. A análise aqui conduzida fundamenta as decisões subsequentes de seleção de características, permitindo uma triagem preliminar entre atributos com alto potencial preditivo e variáveis com menor poder discriminativo.

2.2.1 Distribuição das Classes de Qualidade

A análise inicial da variável alvo revela um cenário de desequilíbrio. Conforme se observa na Figura 2.1, o *dataset* é dominado por classes de qualidade intermédia, com as pontuações 5 e 6 a representarem, cumulativamente, mais de 80% das observações. Em contraste, os vinhos de excelência (qualidade 8) ou de qualidade fraca (qualidade 3) possuem uma representatividade residual. Esta assimetria alerta para a necessidade de métricas de avaliação robustas, uma vez que a precisão global do modelo poderá ser enviesada pela classe maioritária.

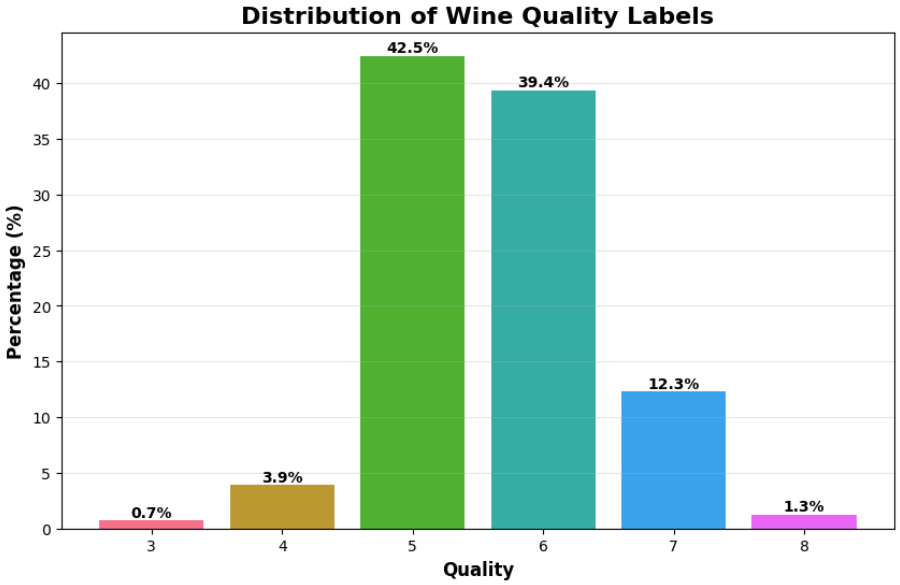

Figura 2.1: Distribuição percentual das classes de qualidade, evidenciando o desequilíbrio entre categorias intermédias e extremas.

2.2.2 Análise Univariada: Determinantes Físico-Químicos

De forma a determinar quais as propriedades que exercem maior influência na classificação, analisou-se o comportamento médio de cada variável em função da qualidade. A inspeção visual permitiu segregar os atributos em dois grupos distintos: aqueles que apresentam uma tendência monótona clara (indicadores fortes) e aqueles cuja variação é irrelevante ou não linear.

Indicadores de Qualidade e Defeito A análise destaca um conjunto de variáveis com forte poder de separação entre classes, divididas pelo sentido da sua correlação:

- **Correlação Positiva:** O **teor alcoólico** e os **sulfatos** apresentam um incremento consistente nos seus valores médios à medida que a qualidade aumenta (ver Figura 2.2). O álcool destaca-se como o discriminador primário para os vinhos de topo (notas 7 e 8), sugerindo que vinhos mais encorpados tendem a ser melhor avaliados. O **ácido cítrico** acompanha também esta tendência, associando a frescura do vinho a uma classificação superior.
- **Correlação Negativa:** Em sentido inverso, a **acidez volátil** e os **cloretos** demonstram uma tendência decrescente com o aumento da qualidade. Enquanto a acidez volátil em excesso se associa a defeitos sensoriais (como notas de vinagre), a presença de cloretos (sais) revela-se igualmente penalizadora. Como se observa nos gráficos, os vinhos de excelência apresentam, invariavelmente, as concentrações médias mais baixas destes dois compostos.

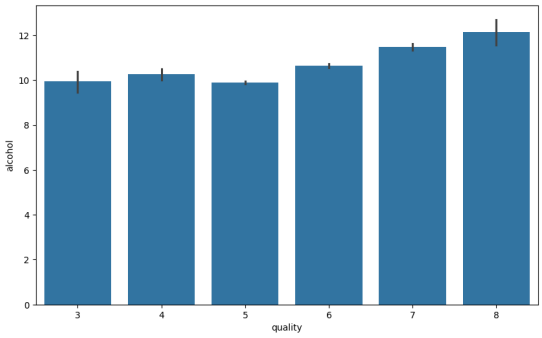

(a) Teor Alcoólico

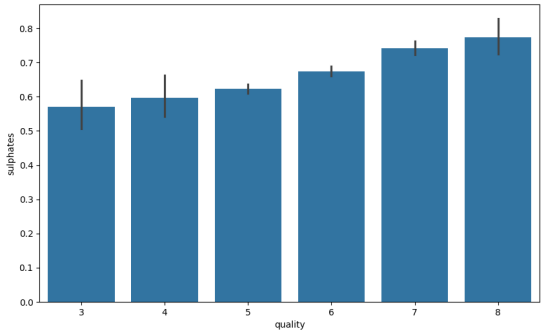

(b) Sulfatos

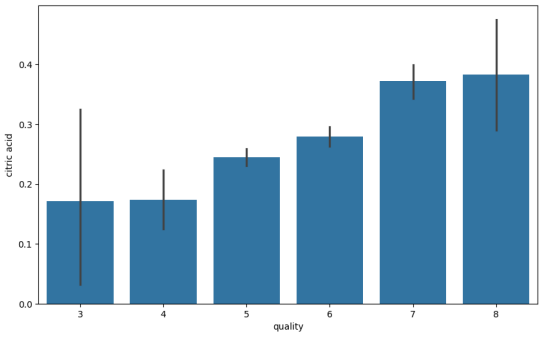

(c) Ácido Cítrico

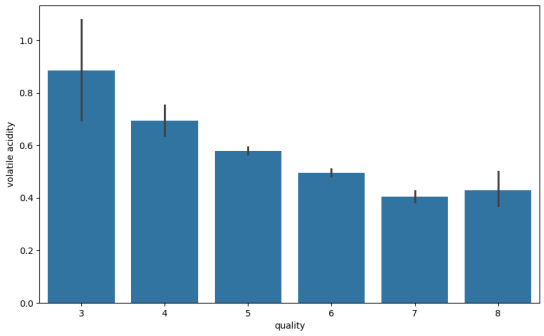

(d) Acidez Volátil

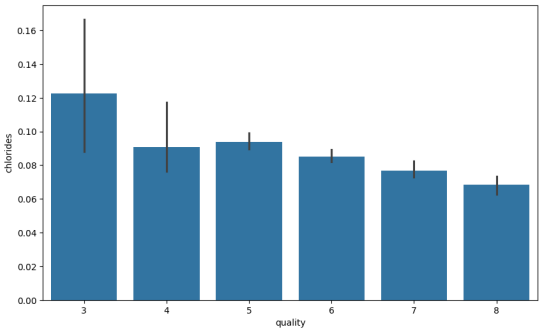

(e) Cloretos

Figura 2.2: Comportamento das variáveis determinantes (positivas e negativas) em função da qualidade.

Variáveis de Baixa Variância As restantes variáveis, nomeadamente o pH, a densidade, o açúcar residual e a acidez fixa, não demonstram padrões de variação monotónicos que permitam distinguir, isoladamente, a qualidade do vinho. Os gráficos referentes a estes atributos, bem como aos dióxidos de enxofre, encontram-se detalhados no Anexo A, servindo como consulta complementar para a caracterização química global das amostras.

2.2.3 Análise de Outliers e Dispersão Estatística

Complementarmente à análise de tendências, procedeu-se ao estudo da dispersão das variáveis independentes, com especial enfoque na identificação de ob-

servações atípicas (*outliers*). A presença destes valores é um fator crítico, uma vez que algoritmos baseados em distâncias ou gradientes, como as *Support Vector Machines* e as Redes Neuronais, são particularmente sensíveis a escalas desproporcionais e pontos fora do padrão, o que pode comprometer a convergência e a capacidade de generalização do modelo.

Para a deteção destas anomalias, aplicou-se o Método do Intervalo Interquartil (IQR), uma abordagem estatística que define como *outlier* qualquer valor situado abaixo de $Q1 - 1.5 \times IQR$ ou acima de $Q3 + 1.5 \times IQR$. A Tabela 2.1 sintetiza os resultados desta análise quantitativa.

Tabela 2.1: Resumo da deteção de outliers pelo método IQR (ordenado por percentagem).

Feature	**Nº Outliers**	**Total Amostras**	**Percentagem (%)**
Residual Sugar	126	1359	9.27
Chlorides	87	1359	6.40
Sulphates	55	1359	4.05
Total Sulfur Dioxide	45	1359	3.31
Fixed Acidity	41	1359	3.02
Density	35	1359	2.58
pH	28	1359	2.06
Free Sulfur Dioxide	26	1359	1.91
Volatile Acidity	19	1359	1.40
Alcohol	12	1359	0.88
Citric Acid	1	1359	0.07

Os resultados mostram que o açúcar residual (*residual sugar*) e os cloretos (*chlorides*) são as variáveis com mais valores atípicos (9.3% e 6.4%, respetivamente). A análise visual (Figura 2.3) confirma que estes atributos possuem distribuições assimétricas, onde um pequeno grupo de vinhos apresenta concentrações de açúcar ou sal muito superiores à média. Em contrapartida, características estruturais como o álcool e o ácido cítrico mostram-se bastante estáveis, com menos de 1% de anomalias.

No contexto deste estudo, estes valores extremos não devem ser interpretados como erros, mas sim como características reais de determinados vinhos. Um vinho pode ser naturalmente mais doce ou mais salino sem que isso constitua uma falha nos dados. Se removêssemos estas amostras, estaríamos a eliminar informação válida sobre tipos específicos de vinho, reduzindo a capacidade do modelo de aprender a classificar casos reais e diversos. Por este motivo, optou-se por manter todos os registos. Para evitar problemas no treino dos algoritmos, a disparidade de escalas será corrigida através da normalização dos dados na fase seguinte.

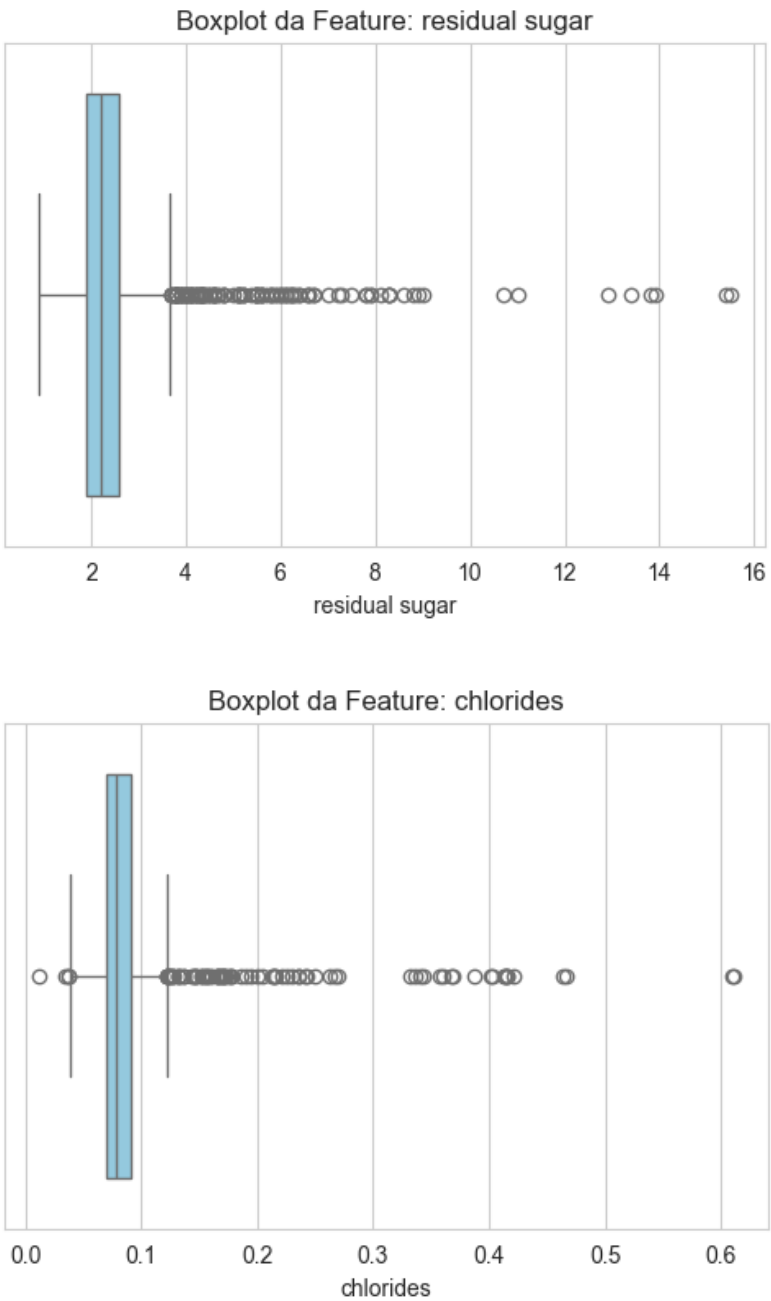

Figura 2.3: Boxplots ilustrando a presença significativa de outliers no açúcar residual e cloretos.

2.3 Preparação dos Dados para Modelação

A etapa final do pré-processamento incidiu na transformação estrutural dos dados, preparando-os para o consumo pelos algoritmos de *machine learning*. Nesta fase, aplicou-se um protocolo de separação e normalização dos dados para assegurar a validade estatística e prevenir o enviesamento dos resultados.

2.3.1 Divisão dos Conjuntos de Treino e Teste

Para avaliar a capacidade de generalização dos modelos, procedeu-se à divisão do *dataset* em dois subconjuntos mutuamente exclusivos: um conjunto de treino (*training set*), utilizado para a otimização dos parâmetros do modelo, e um conjunto de teste (*testing set*), reservado para a avaliação final de desempenho em dados não observados.

Procedeu-se à divisão dos dados numa proporção de 75/25 (*train-test split*), com 75% das amostras destinadas ao treino e 25% ao teste. Face ao desbalanceamento de classes (*class imbalance*) observado na análise exploratória (Secção 2.2), recorreu-se a amostragem estratificada (*stratified sampling*) para garantir que a distribuição das classes de qualidade fosse mantida em ambos os subconjuntos. Esta estratégia previne a sub-representação ou ausência de classes minoritárias (e.g., qualidades 3 e 8) no conjunto de teste, assegurando uma avaliação mais robusta e representativa do desempenho dos modelos.

Para garantir a reprodutibilidade, fixou-se o *random seed* em 42, assegurando que a partição de dados seja determinística e replicável em execuções futuras.

2.3.2 Normalização de Atributos

Os modelos selecionados (SVM e Redes Neuronais) são sensíveis à escala das *features*, pelo que a disparidade de magnitudes entre atributos (e. g., *total sulfur dioxide* $\approx 10^2$ vs. *chlorides* $\approx 10^{-2}$) prejudicaria a convergência e o desempenho preditivo. Em algoritmos baseados em distâncias ou descida de gradiente, *features* de maior magnitude dominam o processo de otimização, suprimindo a contribuição de atributos discriminantes de menor escala.

Para mitigar este efeito, aplicou-se a técnica de *standardization* (*Standard Scaler*), que transforma a distribuição de cada atributo para que apresente uma média nula ($\mu = 0$) e um desvio-padrão unitário ($\sigma = 1$). A transformação de um valor original x para o seu valor normalizado z é dada por:

$$z = \frac{x - \mu}{\sigma} \tag{2.1}$$

É de salientar que, a normalização foi aplicada após a partição dos dados, ajustando o *StandardScaler* exclusivamente no conjunto de treino e aplicando a mesma transformação ao conjunto de teste. Esta abordagem previne *data leakage*, assegurando que informação estatística do conjunto de teste não influencie o pré-processamento, simulando assim um cenário realista de inferência em dados não observados.

Capítulo 3

Metodologia Experimental e Análise de Resultados

Este capítulo descreve a arquitetura experimental desenhada para avaliar o desempenho dos algoritmos de *machine learning* na previsão da qualidade do vinho. A investigação estrutura-se em dois cenários distintos de classificação, ordenados por complexidade crescente: o Cenário A, focado na classificação binária, e o Cenário B, dedicado à classificação multiclasse. Para cada cenário, detalha-se a transformação da variável alvo, a configuração dos modelos selecionados, com ênfase obrigatória nas *Support Vector Machines* (SVM) e Redes Neuronais Artificiais, e a discussão crítica dos resultados obtidos.

3.1 Classificação Binária

A primeira fase experimental aborda um problema de classificação binária, distinguindo vinhos de qualidade superior versus inferior. Esta redução de classes permite isolar as *features* determinantes para a qualidade, minimizando o ruído introduzido pela granularidade da escala ordinal original e facilitando a interpretabilidade dos modelos.

3.1.1 Definição da Variável Alvo e Balanceamento de Classes

Para operacionalizar a classificação binária, a variável ordinal *quality* foi transformada numa variável alvo dicotómica, designada *target*. O critério de binarização baseou-se num *threshold* definido em $quality \geq 6$: amostras com $quality \geq 6$ foram atribuídas à classe positiva (classe 1, "acima da média"), enquanto amostras com $quality \leq 5$ foram atribuídas à classe negativa (classe 0, "abaixo da média").

A binarização resultou numa redistribuição significativa das classes. Contrariamente ao dataset original, que apresentava *class imbalance* severo, a variável *target* exibe uma distribuição aproximadamente balanceada: 719 instâncias positivas (classe 1, 52.9%) e 640 negativas (classe 0, 47.1%), correspondendo a um *imbalance*

ratio de 1.12:1.

Esta distribuição quase uniforme constitui uma vantagem metodológica substancial. A ausência de *class imbalance* severo mitiga o *bias* natural dos algoritmos de aprendizagem em direção à classe maioritária, permitindo que métricas standard como *accuracy* reflitam adequadamente a capacidade de generalização do modelo, sem a inflação artificial frequentemente observada em datasets desbalanceados.

3.1.2 Otimização de Hiperparâmetros em Redes Neuronais

A primeira abordagem de modelação recaiu sobre as Redes Neuronais, especificamente a arquitetura *Multilayer Perceptron* (MLP). Dada a sensibilidade destes modelos à configuração inicial e aos hiperparâmetros, não se procedeu a uma aplicação direta dos valores por defeito, optando-se antes por uma estratégia de otimização (*Grid Search*) com validação robusta.

Metodologia de Seleção e Espaço de Busca

O espaço de hiperparâmetros foi definido para explorar variações na arquitetura da rede, estratégias de regularização e algoritmos de otimização. Realizou-se uma pesquisa (*grid search*) sobre as seguintes configurações:

- **Arquitetura (*hidden_layer_sizes*):** Variação na profundidade e largura, testando configurações simples e profundas: `[(16,), (32,), (64,), (128,), (32, 16), (64, 32), (64, 32, 16)]`.
- **Regularização (*alpha*):** Penalização L2 para controlo de *overfitting*: `[0.0001, 0.001, 0.01, 0.05, 0.1]`.
- **Funções de Ativação:** `['relu', 'tanh', 'logistic']`.
- **Otimização (*solver*):** Algoritmos `['adam', 'sgd']`.
- **Taxa de Aprendizagem:** Estratégias `['constant', 'adaptive', 'invscaling']` com valores iniciais `[0.0001, 0.001, 0.01]`.
- **Iterações:** Fixadas num limite superior de `2500` para garantir a convergência.

O critério de seleção primário foi a *Test Accuracy* média obtida após 3 repetições com *seeds* aleatórias distintas, penalizando configurações que maximizassem apenas o desempenho no treino (memorização).

Análise Crítica e Seleção do Modelo

A Tabela 3.1 apresenta as cinco configurações com melhor desempenho. Observa-se que todas convergiram para a função de ativação **tanh** e o otimizador **SGD**, sugerindo que esta combinação é particularmente adequada à geometria da superfície de erro deste problema de classificação.

Tabela 3.1: Top 5 Configurações de Redes Neuronais (Média $\pm$ Desvio Padrão de 3 execuções).

Rank	Arquitetura	Alpha	Learning Rate	Train Acc	Test Acc	Gap
1	(64,)	0.05	Adaptive	79.98% $\pm$ 1.46%	77.16% $\pm$ 0.60%	2.82% $\pm$ 1.02%
2	(128,)	0.0001	Constant	**81.32% $\pm$ 1.94%**	77.16% $\pm$ 0.37%	4.16% $\pm$ 2.05%
3	(128,)	0.01	Constant	80.83% $\pm$ 1.61%	77.06% $\pm$ 0.96%	3.77% $\pm$ 2.21%
4	**(64,)**	**0.05**	**Constant**	79.36% $\pm$ 1.71%	77.06% $\pm$ 0.96%	**2.30% $\pm$ 0.97%**
5	(128,)	0.05	Adaptive	79.56% $\pm$ 0.85%	76.96% $\pm$ 0.37%	2.59% $\pm$ 0.76%

Embora as configurações 1 e 2 apresentem *test accuracy* marginalmente superior (77.16%), selecionou-se a **Configuração 4** como modelo final. Esta decisão fundamenta-se numa análise de *trade-off* entre desempenho preditivo e capacidade de generalização:

1. **Mitigação de *Overfitting*:** A Configuração 2, apesar de alcançar a maior *training accuracy* (81.32%), exibe o maior *generalization gap* (4.16%), indicando memorização de padrões não genuínos nos dados de treino. Este comportamento é expectável dado o sub-dimensionamento da regularização ($\alpha = 0.0001$) face à complexidade da arquitetura (128 neurónios). Em contraste, a Configuração 4 apresenta o menor *gap* do conjunto (**2. 30%**), evidenciando superior capacidade de generalização para dados não observados.

2. **Estabilidade entre Execuções:** A variância do *gap* na Configuração 4 ($\pm$ 0.97%) é substancialmente inferior à observada nas configurações de topo (e.g., $\pm$ 2.05% na Configuração 2). Esta baixa variância indica robustez à inicialização aleatória de pesos e à estocasticidade do treino, propriedades críticas para garantir desempenho consistente em produção.

3. **Diferença Estatisticamente Não Significativa:** A diferença de *accuracy* entre as Configurações 1 e 4 é de apenas 0.10 pontos percentuais. Considerando os desvios padrão observados ($\pm$ 0.60% e $\pm$ 0.96%, respetivamente), esta diferença situa-se dentro da margem de variabilidade estatística, não constituindo evidência de superioridade preditiva significativa.

4. **Simplicidade Arquitetural:** A Configuração 4 alcança desempenho competitivo com apenas 64 neurónios—metade da capacidade das Configurações 2, 3 e 5 (128 neurónios). Esta simplicidade reduz o risco de *overfitting*, o custo computacional de inferência, e facilita a interpretabilidade do modelo.

Em síntese, selecionou-se a arquitetura **MLP(64)** com ativação **tanh**, otimizador **SGD** (*learning rate* constante) e regularização L2 $\alpha = 0.05$. Esta configuração sa-

crifica 0.1 pontos percentuais de *accuracy* nominal em favor de um modelo substancialmente mais robusto, estável e com capacidade de generalização comprovadamente superior.

3.1.3 Análise de Robustez e Estabilidade

A natureza estocástica das Redes Neuronais, decorrente da inicialização aleatória de pesos e da otimização via SGD, introduz variabilidade no desempenho preditivo. Uma única execução fornece apenas uma estimativa pontual, insuficiente para caracterizar a distribuição de desempenho esperada. Na fase de otimização de hiperparâmetros (Secção 3.1.2), cada configuração foi avaliada através de 3 execuções independentes (com diferentes seeds), permitindo uma comparação preliminar entre arquiteturas. Contudo, para validar rigorosamente a configuração final, realizou-se uma análise de estabilidade mais abrangente.

Conduziram-se 30 execuções independentes da arquitetura selecionada (MLP(64), tanh, SGD, $\alpha = 0.05$), alterando exclusivamente o *random state* em cada repetição. Este protocolo permite: (i) quantificar a variância no desempenho atribuível à estocasticidade do treino; (ii) estabelecer intervalos de confiança estatisticamente válidos (95%) para as métricas reportadas; (iii) identificar potenciais instabilidades ou sensibilidade excessiva à inicialização. O incremento de 3 para 30 repetições fornece poder estatístico adequado para inferências sobre a robustez do modelo.

Análise da Distribuição de Resultados

A Tabela 3.2 apresenta as estatísticas descritivas de desempenho obtidas nas 30 execuções independentes.

Tabela 3.2: Estatísticas descritivas de desempenho após 30 execuções independentes do modelo final

Métrica Estatística	**Valor (Test Accuracy)**
Média (μ)	75.97%
Desvio Padrão (σ)	$\pm$ 1.48%
Coeficiente de Variação (CV)	1.95%
Mínimo	72.65%
Máximo	77.94%
Intervalo de Confiança (95%)	[75.44%, 76.50%]

A *test accuracy* média de **75. 97% (**$\sigma = 1.48\%$**)** corresponde a um coeficiente de variação de **1.95%**, indicando elevada estabilidade. O modelo não apresenta sensibilidade significativa à inicialização aleatória, assegurando desempenho consistente entre execuções.

Embora o valor máximo (77.94%) supere ligeiramente a média observada na otimização de hiperparâmetros, reporta-se o **intervalo de confiança a 95% [75.44%,**

76.50%] como estimador mais robusto da capacidade preditiva real.

Análise de Desempenho por Classe

Em consonância com a métrica prioritária definida para este estudo, a avaliação centra-se na **accuracy** global. O valor médio de **75.97%** obtido nas 30 execuções quantifica a capacidade do classificador em atribuir a *label* correta. Contudo, para validar que esta taxa de acerto reflete desempenho equilibrado, e não enviesamento em favor da classe maioritária, é essencial analisar métricas discriminadas por classe.

A Tabela 3.3 apresenta *precision*, *recall* e *F1-score* médios para ambas as classes, permitindo identificar potenciais assimetrias no desempenho preditivo.

Tabela 3.3: Métricas de desempenho por classe em 30 execuções independentes ($\mu \pm \sigma$).

Classe	**Precision**	**Recall**	**F1-Score**
Classe 0 (Baixa Qualidade)	72.32% ± 1. 58%	**79.33% ± 2.44%**	75.64% ± 1.59%
Classe 1 (Alta Qualidade)	**79.93% ± 1.86%**	72.98% ± 2. 07%	76.27% ± 1.50%
Macro-Average	76.13% ± 1.51%	76.16% ± 1.85%	75.96% ± 1.43%

A análise das métricas discriminadas revela desempenho equilibrado entre classes, com complementaridade entre *precision* e *recall*:

- **Classe 0 (Baixa Qualidade):** Apresenta *recall* elevado (79.33%), indicando que o modelo identifica corretamente a maioria das instâncias desta classe, com baixa taxa de falsos negativos. O desvio padrão de ± 2.44% confirma a estabilidade desta capacidade.
- **Classe 1 (Alta Qualidade):** Apresenta *precision* elevada (79.93%), indicando que as predições positivas são predominantemente corretas, com baixa taxa de falsos positivos. O desvio padrão de ± 1.86% valida a robustez desta métrica.
- **Equilíbrio entre Classes:** Os F1-scores de ambas as classes (75.64% e 76.27%) são estatisticamente equivalentes, evidenciando ausência de *bias* sistemático. O *macro-average* de 75.96% aproxima-se da *accuracy* global (75. 97%), confirmando que o desempenho é balanceado e não resulta do favorecimento de uma classe específica.

Conclui-se que a *accuracy* de ∼76% constitui um indicador robusto e não enviesado da capacidade preditiva do modelo, refletindo desempenho consistente em ambas as classes.

3.1.4 Ensemble Learning: Random Forest

A segunda abordagem metodológica explorou algoritmos baseados em árvores de decisão, especificamente o método de *ensemble learning* designado *Random Forest* (RF). Contrariamente às NN, que aprendem fronteiras de decisão globais através de composições não-lineares, o RF agrega predições de múltiplas *decision trees* treinadas independentemente, combinando-as via *majority voting* para classificação. A escolha deste algoritmo fundamenta-se na sua capacidade de mitigar o problema de *overfitting*, típico das árvores de decisão individuais.

Otimização de Hiperparâmetros

De forma a maximizar o desempenho do classificador, definiu-se um espaço de pesquisa abrangente que controla tanto a complexidade das árvores individuais como a dimensão do *ensemble*. O protocolo de otimização (*Grid Search*) avaliou as seguintes configurações:

- **Dimensão do Ensemble (*n_estimators*):** Testaram-se florestas com `[200, 300, 500]` árvores.
- **Controlo de Profundidade (*max_depth*):** Para limitar a complexidade e prevenir a memorização do ruído, avaliaram-se profundidades máximas de `[5, 10, 20]` e a opção `None` (crescimento ilimitado).
- **Critérios de Divisão (*min_samples*):** Testaram-se restrições à criação de novos nós (*split*: `[2, 5, 10]`) e à dimensão mínima das folhas (*leaf*: `[1, 2, 4]`).
- **Amostragem (*bootstrap*):** Avaliou-se a utilização de amostragem com reposição (`True`) versus o uso do *dataset* completo (`False`), para verificar o impacto da diversidade dos dados de treino na robustez do *ensemble*.

Tal como na abordagem anterior, a seleção do modelo final baseou-se na maximização da *Test Accuracy*, ponderada pela análise do *gap* de generalização para garantir a ausência de *overfitting*.

3.1.5 Otimização de Hiperparâmetros em Random Forest

Após a definição do espaço de pesquisa, procedeu-se à avaliação sistemática das combinações de hiperparâmetros através de *Grid Search*. O objetivo consistiu em encontrar o equilíbrio ideal entre a complexidade do *ensemble* (número de estimadore) e a regularização das árvores individuais (profundidade e amostras mínimas), maximizando a generalização.

Análise Crítica e Seleção do Modelo

A Tabela 3.4 sumariza as cinco configurações com melhor desempenho preditivo no conjunto de teste. A análise destes resultados evidencia o impacto crítico do hiperparâmetro `max_depth` no comportamento do classificador.

Tabela 3.4: Top 5 Configurações de Random Forest (Ordenadas por Test Accuracy).

Número	Configuração (Resumo)	Max Depth	N Estimators	Train Acc	Test Acc	Gap
1	Depth=None, Split=10	None	300	**95.75%**	78.33%	17.41%
2	Depth=10, Split=10	10	500	93.92%	78.24%	15.68%
3	Depth=10, Split=2	10	200	98.89%	78.24%	20.65%
4	**Depth=5, Split=5**	**5**	**200**	82.17%	78.24%	**3.94%**
5	Depth=10, Split=2	10	500	99.05%	78.24%	20.82%

A análise da tabela revela um *trade-off* entre desempenho nominal no treino e capacidade de generalização, motivando a seleção da **Configuração 4** em detrimento das três primeiras. Esta decisão fundamenta-se nos seguintes critérios técnicos:

1. **Evidência de *Overfitting* Severo:** A Configuração 1 utiliza `max_depth=None`, permitindo crescimento irrestrito das árvores até satisfazer os critérios de paragem por amostragem mínima. Este comportamento resulta em *training accuracy* de 95.75%, mas com *generalization gap* de **17.41%**—evidência de memorização dos dados. As Configurações 3 e 5 exibem *overfitting* ainda mais severo, com *gaps* superiores a 20% e *training accuracy* próxima de 99%, indicando aprendizagem de ruído específico do conjunto de treino.

2. **Regularização Eficaz via Limitação de Profundidade:** A Configuração 4 impõe `max_depth=5`, restringindo a complexidade das árvores individuais. Esta limitação atua como regularizador estrutural, impedindo a construção de regras de decisão excessivamente específicas. A *training accuracy* reduz para 82.17%, próxima da *test accuracy* (78.24%), resultando num *gap* de apenas **3.94%**. Este comportamento indica aprendizagem de padrões generalizáveis, não memorização de instâncias.

3. **Eficiência Computacional:** A Configuração 4, com 200 estimadores e profundidade máxima de 5, apresenta complexidade substancialmente inferior às alternativas (que utilizam 500 estimadores e árvores profundas), resultando em menor custo de treino e inferência, sem comprometer o desempenho preditivo.

Selecionou-se, assim, a configuração com **200 estimadores**, `max_depth=5`, `min_samples_split=5` e `bootstrap=True`. Esta escolha privilegia robustez e capacidade de generalização, rejeitando configurações que, apesar de maior *training accuracy*, exibem *overfitting* severo e instabilidade preditiva.

3.1.6 Análise de Robustez e Estabilidade

Para aferir a fiabilidade da configuração selecionada (**200 estimadores, profundidade 5**), replicou-se o protocolo experimental de estabilidade, submetendo o modelo a 30 execuções independentes. Neste procedimento, introduziu-se variação nas *seeds*. Esta análise é fundamental para validar empiricamente se a técnica de *Bagging (Bootstrap Aggregating)* foi eficaz na mitigação da variância estrutural, cumprindo um dos objetivos teóricos primordiais dos algoritmos de *Random Forest*.

Análise da Distribuição de Resultados

A Tabela 3.5 sumariza as métricas globais obtidas. A comparação direta com os resultados das Redes Neuronais (Secção 3.1.3) evidencia a superioridade do Random Forest em termos de consistência estatística.

Tabela 3.5: Estatísticas descritivas do Random Forest após 30 execuções independentes.

Métrica Estatística	**Valor (Test Accuracy)**
Média (μ)	77.61%
Desvio Padrão (σ)	$\pm$ 0.53%
Coeficiente de Variação (CV)	0.68%
Mínimo	76.18%
Máximo	78.53%
Intervalo de Confiança (95%)	[77.42%, 77.80%]

O modelo apresenta uma *test accuracy* média de **77.61%**, superando o desempenho médio da abordagem anterior ($\sim$76%). Contudo, o indicador mais relevante é o desvio padrão residual de apenas **$\pm$ 0.53%**. Este valor resulta num Coeficiente de Variação de **0.68%**, substancialmente inferior ao observado nas Redes Neuronais (1.95%).

Estes dados validam o efeito estabilizador do *Ensemble Learning*: ao agregar as decisões de 200 árvores limitadas em profundidade, o sistema torna-se praticamente imune a variações na amostragem de treino, garantindo uma previsibilidade operacional de excelência. O intervalo de confiança estreito ([77.42%, 77.80%]) reforça a solidez desta inferência.

Decomposição da Accuracy

Para uma caracterização detalhada do desempenho do classificador, analisa-se o comportamento discriminado por classe (Tabela 3.6).

A análise das métricas evidencia a robustez do modelo em ambas as categorias, destacando-se os seguintes aspetos:

Tabela 3.6: Métricas médias e desvio padrão por classe no Random Forest ($\mu \pm \sigma$).

Classe	**Precision**	**Recall**	**F1-Score**
Classe 0 (Under-Average)	73.71% $\pm$ 0.63%	**81.50% $\pm$ 0.86%**	77.40% $\pm$ 0.53%
Classe 1 (Above-Average)	**81.85% $\pm$ 0.66%**	74.15% $\pm$ 0.88%	77.81% $\pm$ 0.57%
Macro-Average	77.78% $\pm$ 0.51%	77.82% $\pm$ 0.64%	77.60% $\pm$ 0.53%

- **Sensibilidade à Classe 0 (Recall):** O modelo atinge um *Recall* médio de **81.50%** na classe "Abaixo da Média". Este valor indica que o algoritmo é capaz de recuperar corretamente a vasta maioria das instâncias desta classe, superando a sensibilidade registada nas Redes Neuronais (79.33%). A estabilidade desta métrica ($\sigma = \pm 0.86\%$) demonstra consistência na identificação dos padrões associados à menor qualidade.

- **Precisão na Classe 1 (Precision):** A precisão na classe "Acima da Média"ascende a **81.85%**. Este indicador revela que as predições positivas do modelo possuem uma elevada probabilidade de acerto, minimizando a taxa de falsos positivos (inferior a 19%).

- **Equilíbrio de Desempenho (Isotropia):** Observa-se uma equivalência estatística entre os valores de F1-Score das duas classes (77.40% vs 77.81%). Este equilíbrio demonstra que o classificador não apresenta enviesamento em favor de nenhuma das categorias, mantendo uma capacidade preditiva homogénea independentemente do rótulo real da amostra.

Conclusão do Cenário com Random Forest

Em síntese, a abordagem baseada em *Random Forest* demonstrou superioridade face às Redes Neuronais para este domínio específico. A configuração otimizada não só incrementou a *accuracy* média em cerca de 1.6 pontos percentuais, como reduziu a variabilidade dos resultados em quase três vezes (σ de 1.48% para 0.53%). O controlo eficaz do *generalization gap* ($\sim$3.94%) confirma que a restrição de profundidade (`max_depth=5`) atuou como um regularizador competente, resultando num classificador robusto e estável.

Capítulo 4

Conclusão e Trabalho Futuro