1 2 9 0

UNIVERSIDADE D
COIMBRA

Tomás Ferreira & Eduardo Pereira

CLASSIFICAÇÃO DA QUALIDADE DE VINHOS BASEADA EM ATRIBUTOS FÍSICO-QUÍMICOS

ANÁLISE COMPARATIVA EM CENÁRIOS DE CLASSIFICAÇÃO BINÁRIA E MULTICLASSE

Trabalho realizado no âmbito da unidade curricular de Machine Learning, do Mestrado em Inteligência Artificial

Novembro 2025

Conteúdo

1 Introdução **1**
1.1 Contextualização e Formulação do Problema 1
1.2 Descrição do Dataset 2

2 Análise Exploratória e Pré-processamento de Dados **5**
2.1 Verificação da Integridade e Limpeza de Dados 5
2.2 Análise Exploratória de Dados 6
2.2.1 Distribuição das Classes de Qualidade 6
2.2.2 Análise Univariada: Determinantes Físico-Químicos 7

3 Conclusão e Trabalho Futuro **11**

Lista de Figuras

2.1 Distribuição percentual das classes de qualidade, evidenciando o desequilíbrio entre categorias intermédias e extremas. 7
2.2 Comportamento das variáveis determinantes (positivas e negativas) em função da qualidade. 9

Lista de Tabelas

Capítulo 1

Introdução

O presente documento apresenta o relatório do projeto realizado no âmbito da unidade curricular de Machine Learning, com o objetivo de aplicar técnicas de aprendizagem automática à classificação da qualidade de vinhos. O estudo baseia-se num conjunto de dados que reúne propriedades físico-químicas de amostras vinícolas, explorando a capacidade de criar modelos preditivos que avaliem a qualidade do produto através destas características.

Este capítulo estrutura os fundamentos do trabalho em duas secções principais: a primeira contextualiza o problema e a segunda descreve detalhadamente o *dataset*, constituindo elementos essenciais para compreender as escolhas metodológicas descritas nos capítulos seguintes.

1.1 Contextualização e Formulação do Problema

A presente investigação aborda o desafio de determinar automaticamente a qualidade de vinhos, utilizando exclusivamente as suas propriedades físico-químicas como base de análise. Dado que o estudo utiliza um conjunto de dados onde a avaliação de cada amostra é conhecida, este problema define-se tecnicamente como uma tarefa de aprendizagem supervisionada (*supervised learning*). O objetivo central consiste na construção de modelos capazes de identificar padrões nos dados e aplicar esse conhecimento para prever a qualidade de novas amostras. A complexidade desta tarefa é explorada através de duas abordagens distintas, desenhadas para testar a capacidade de generalização dos algoritmos perante diferentes níveis de detalhe.

Numa primeira fase, o problema é tratado como uma classificação binária, onde se procura separar as amostras em duas categorias: vinhos de qualidade "abaixo da média"e "acima da média". Esta simplificação estratégica permite concentrar a análise na identificação dos atributos que mais contribuem para uma distinção fundamental de qualidade. Complementarmente, o estudo expande-se para um cenário de classificação multiclasse, mantendo a escala original de avaliação. Este segundo cenário impõe um grau de dificuldade superior, exigindo aos modelos uma precisão maior para identificar o nível exato de qualidade de cada amostra.

A avaliação transversal destes modelos, tanto no cenário binário como na abordagem multiclasse, orienta-se pela necessidade de maximizar a fiabilidade global do sistema de previsão. Neste contexto, define-se como critério prioritário a *accuracy*, métrica que quantifica a proporção de instâncias corretamente classificadas face ao total de amostras. A escolha desta métrica como indicador principal baseia-se na premissa de que o valor operacional do modelo reside na sua capacidade de atribuir o rótulo correto a cada amostra, independentemente da complexidade do espaço de decisão. Embora os dois cenários apresentem níveis de detalhe distintos, o objetivo permanece constante: garantir uma taxa de acerto elevada que valide a utilidade do sistema num contexto de triagem automática. Ao uniformizar a métrica de avaliação, torna-se possível comparar diretamente a eficácia dos modelos e compreender como o aumento da complexidade do problema afeta a capacidade de previsão dos algoritmos.

1.2 Descrição do Dataset

O suporte experimental desta investigação assenta no conjunto de dados *Wine Quality*. O *dataset* é constituído por um total de 1599 instâncias, onde cada registo representa uma amostra distinta caracterizada por um vetor de doze variáveis. As primeiras onze variáveis correspondem às características físico-químicas medidas para cada amostra (*features*), enquanto a décima segunda fornece a classificação atribuída à sua qualidade, servindo assim como variável-alvo do estudo.

As variáveis independentes são exclusivamente numéricas e contínuas, refletindo medições laboratoriais objetivas. O conjunto de atributos compreende a acidez fixa, acidez volátil, ácido cítrico, açúcar residual, cloretos, dióxido de enxofre livre, dióxido de enxofre total, densidade, pH, sulfatos e teor alcoólico. Uma análise preliminar às estatísticas descritivas destas variáveis revela uma disparidade significativa nas escalas de grandeza. Por exemplo, enquanto a variável *total sulfur dioxide* apresenta valores que ascendem a 289 mg/dm^3, outros atributos como os *chlorides* ou a *density* variam em intervalos decimais restritos. Esta heterogeneidade de domínios sugere a necessidade de aplicar técnicas de normalização durante a fase de pré-processamento, a fim de evitar que algoritmos sensíveis à magnitude dos dados sejam enviesados por variáveis com valores absolutos superiores.

Relativamente à variável dependente, denominada *quality*, esta é definida numa escala ordinal discreta. Embora a escala teórica compreenda valores inteiros entre zero e dez, os dados empíricos observados no *dataset* restringem-se ao intervalo entre 3 e 8. A análise da distribuição desta variável evidencia um acentuado desequilíbrio de classes. A grande maioria das amostras concentra-se nas categorias intermédias, especificamente nas pontuações 5 e 6, que, em conjunto, representam mais de 80% do volume total de dados. Em contrapartida, as classes representativas de qualidade inferior (3 e 4) ou superior (8) possuem uma representatividade residual. Este desequilíbrio coloca desafios particulares à modelação, nomeadamente o risco de o classificador privilegiar as classes maioritárias em detrimento da capacidade de detetar casos de excelência ou defeito.

Por fim, no que concerne à integridade dos dados, verificou-se a inexistência de valores em falta (*missing values*) em qualquer uma das colunas, o que atesta a qualidade técnica da recolha e dispensa a aplicação de métodos de imputação de dados. Deste modo, o conjunto de dados apresenta-se como uma base robusta, embora desafiante devido à sua assimetria, para o treino e validação dos modelos de aprendizagem supervisionada propostos.

Capítulo 2

Análise Exploratória e Pré-processamento de Dados

A qualidade dos modelos de *Machine Learning* está intrinsecamente dependente da qualidade dos dados que os alimentam. Este capítulo descreve a metodologia aplicada no tratamento preliminar do conjunto de dados, abrangendo desde a verificação da integridade estrutural até à análise exploratória das variáveis e consequente transformação para os formatos adequados aos algoritmos de classificação selecionados.

2.1 Verificação da Integridade e Limpeza de Dados

A etapa inicial do processamento de dados consistiu numa auditoria à qualidade da informação, de forma a identificar e mitigar potenciais inconsistências que pudessem comprometer a validade dos resultados experimentais. Esta verificação focou-se primordialmente em dois vetores: a existência de*missing values* e a presença de amostras duplicadas.

Numa primeira análise, confirmou-se a integridade estrutural do *dataset*, não tendo sido detetados quaisquer valores nulos nas doze variáveis analisadas. Esta ausência de dados em falta dispensou a necessidade de aplicar técnicas de imputação, preservando a distribuição original das medições físico-químicas.

Contudo, a análise de redundância revelou uma repetição significativa de informação. Foram identificadas e removidas 240 instâncias duplicadas, o que corresponde a aproximadamente 15% do volume inicial de dados. Embora em contextos biológicos possa ocorrer que duas amostras apresentem medições idênticas, a presença desta magnitude de duplicados acarreta riscos metodológicos, nomeadamente o enviesamento do modelo em favor das classes mais representadas e a possibilidade de *data leakage*.

A prevenção deste fenómeno é crítica para a validade do estudo. Dada a natureza aleatória da divisão dos dados em conjuntos de treino e teste (*train-test split*), a manutenção de dados duplicados resultaria, com elevada probabilidade, na pre-

sença de instâncias iguais em ambos os subconjuntos. Tal cenário permitiria ao modelo "memorizar"as características específicas destas amostras durante a fase de treino e ser subsequentemente avaliado sobre essa mesma informação na fase de teste. Esta contaminação inflacionaria artificialmente as métricas de desempenho, criando uma ilusão de competência preditiva que não corresponderia à capacidade real de generalização do modelo perante dados inéditos.

De forma a garantir a robustez estatística e a independência das observações, optou-se pela exclusão integral destes registos. Esta operação de limpeza resultou na redução do *dataset* de 1599 para 1359 amostras únicas, assegurando que cada instância apresentada aos algoritmos de classificação representa um perfil físico-químico distinto.

2.2 Análise Exploratória de Dados

Após a garantia da integridade dos registos, procedeu-se à Análise Exploratória de Dados (EDA). Esta etapa visa compreender a estrutura subjacente das variáveis e identificar visualmente os padrões de distribuição que relacionam as propriedades físico-químicas com a qualidade atribuída ao vinho. A análise aqui conduzida fundamenta as decisões subsequentes de seleção de características, permitindo uma triagem preliminar entre atributos com alto potencial preditivo e variáveis com menor poder discriminativo.

2.2.1 Distribuição das Classes de Qualidade

A análise inicial da variável alvo revela um cenário de desequilíbrio. Conforme se observa na Figura 2.1, o *dataset* é dominado por classes de qualidade intermédia, com as pontuações 5 e 6 a representarem, cumulativamente, mais de 80% das observações. Em contraste, os vinhos de excelência (qualidade 8) ou de qualidade fraca (qualidade 3) possuem uma representatividade residual. Esta assimetria alerta para a necessidade de métricas de avaliação robustas, uma vez que a precisão global do modelo poderá ser enviesada pela classe maioritária.

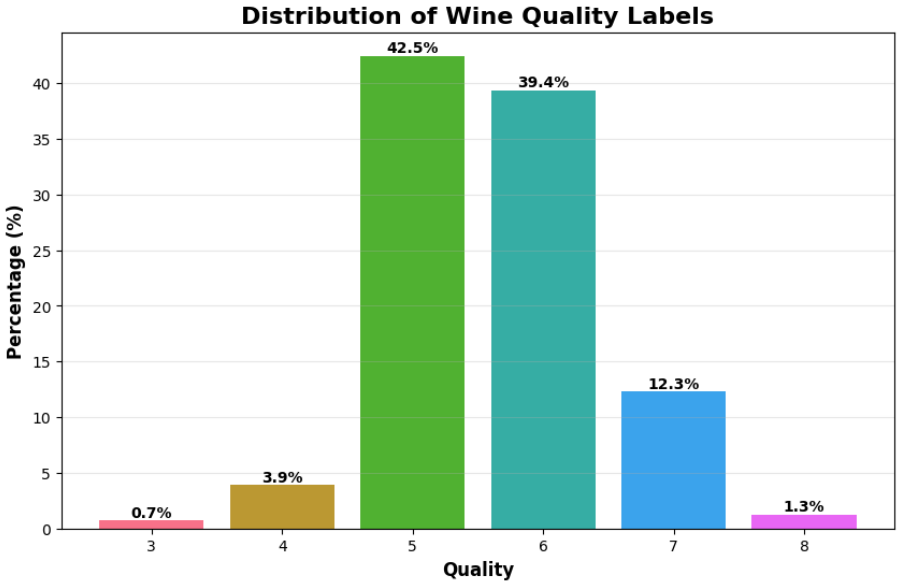

Figura 2.1: Distribuição percentual das classes de qualidade, evidenciando o desequilíbrio entre categorias intermédias e extremas.

2.2.2 Análise Univariada: Determinantes Físico-Químicos

De forma a determinar quais as propriedades que exercem maior influência na classificação, analisou-se o comportamento médio de cada variável em função da qualidade. A inspeção visual permitiu segregar os atributos em dois grupos distintos: aqueles que apresentam uma tendência monótona clara (indicadores fortes) e aqueles cuja variação é irrelevante ou não linear.

Indicadores de Qualidade e Defeito A análise destaca um conjunto de variáveis com forte poder de separação entre classes, divididas pelo sentido da sua correlação:

- **Correlação Positiva:** O **teor alcoólico** e os **sulfatos** apresentam um incremento consistente nos seus valores médios à medida que a qualidade aumenta (ver Figura 2.2). O álcool destaca-se como o discriminador primário para os vinhos de topo (notas 7 e 8), sugerindo que vinhos mais encorpados tendem a ser melhor avaliados. O **ácido cítrico** acompanha também esta tendência, associando a frescura do vinho a uma classificação superior.
- **Correlação Negativa:** Em sentido inverso, a **acidez volátil** e os **cloretos** demonstram uma tendência decrescente com o aumento da qualidade. Enquanto a acidez volátil em excesso se associa a defeitos sensoriais (como notas de vinagre), a presença de cloretos (sais) revela-se igualmente penalizadora. Como se observa nos gráficos, os vinhos de excelência apresentam, invariavelmente, as concentrações médias mais baixas destes dois compostos.

Variáveis de Baixa Variância As restantes variáveis, nomeadamente o pH, a densidade, o açúcar residual e a acidez fixa, não demonstram padrões de variação monotónicos que permitam distinguir, isoladamente, a qualidade do vinho. Os gráficos referentes a estes atributos, bem como aos dióxidos de enxofre, encontram-se detalhados no Anexo A, servindo como consulta complementar para a caracterização química global das amostras.

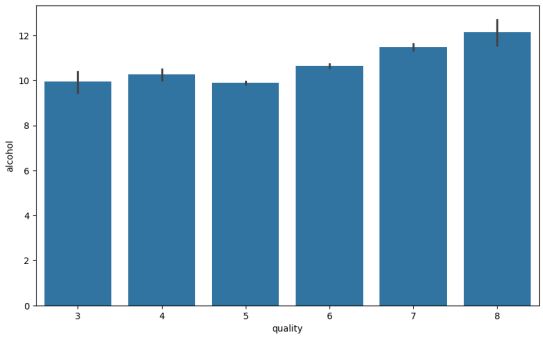

(a) Teor Alcoólico

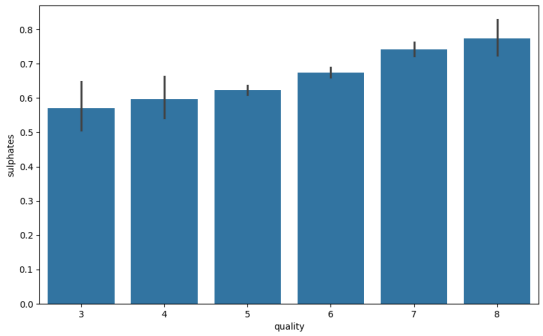

(b) Sulfatos

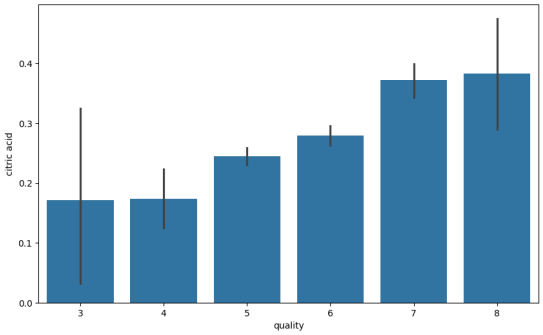

(c) Ácido Cítrico

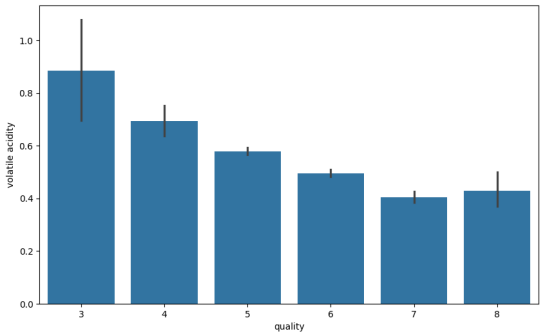

(d) Acidez Volátil

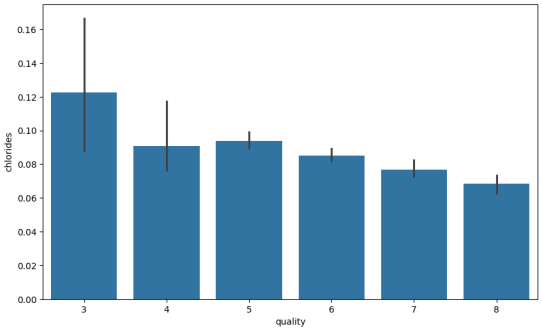

(e) Cloretos

Figura 2.2: Comportamento das variáveis determinantes (positivas e negativas) em função da qualidade.

Capítulo 3

Conclusão e Trabalho Futuro